

Ad Soyad : BEYZA UĞUR

Bu çalışmada, **bands.dat** veri seti üzerinde veri ön işleme ve istatistiksel analiz teknikleri uygulanmıştır. Analiz kapsamında veri setinde **13. , 14. , 15. ve 16. nitelikleri** (attributes) yani **"ESA_amperage", "Wax", "Hardener", "Roller_durometer"** nitelikleri seçilerek kullanılmış; hedef değişken (sınıflandırma) olarak ise **20. nitelik olan "Band_type"** bilgisi temel alınmıştır.

Veri ön işleme aşamasında gerekli nitelikler seçilmiş ve veri setinin doğru okunup okunmadığını kontrol etmek amacıyla ilk 5 satır görüntülenmiştir. :

Metninizi buraya girin 1

	ESA_amperage	Wax	Hardener	Roller_durometer	Band_type
0	0.0	2.5	1.0	34.0	band
1	0.0	2.5	0.7	34.0	noband
2	0.0	2.5	1.3	40.0	noband
3	0.0	2.3	0.6	35.0	noband
4	0.0	2.5	0.8	40.0	noband

1. X veri kümesinin e-postada belirtilen her bir niteliği (attribute) için beş sayı özeti (five number summary), ortalama (mean), mod (mode), çeyrekler arası genişlik (InterQuartile Range), varyans (variance), standart sapma (standard deviation) ve varsa aykırı (outlier) değerlerini hesaplayınız. Her bir nitelik için kutu diyagramı (boxplot) çizimini gerçekleştiriniz.


KOD ÇIKTISI :

	Attribute	Minimum	Q1	Median	Q3	Maximum	Mean	Mode	IQR	Variance	Std	Outlier Count
0	ESA_amperage	0.0	0.0	0.0	0.0	6.0	0.017808	0.0	0.0	0.099270	0.315071	2
1	Wax	0.0	2.4	2.5	2.7	3.1	2.403699	2.5	0.3	0.316669	0.562733	49
2	Hardener	0.0	0.8	1.0	1.0	3.0	0.960137	1.0	0.2	0.112754	0.335789	79
3	Roller_durometer	28.0	30.0	34.0	38.0	50.0	34.515068	30.0	8.0	17.080129	4.132811	0

TABLO:


	ESA_ amperage	Wax	Hardener	Roller_ durometer
Minimum	0.0	0.0	0.0	28.0
Birinci Çeyrek (Q1)	0.0	2.4	0.8	30.0
Medyan (Q2)	0.0	2.5	1.0	34.0
Üçüncü Çeyrek (Q3)	0.0	2.7	1.0	38.0
Maksimum	6.0	3.1	3.0	50.0
Ortalama (Mean)	0.017808	2.403699	0.960137	34.515068
Mod (Mode)	0.0	2.5	1.0	30.0
Çeyrekler Arası Genişlik (InterQuartile Range)	0.0	0.3	0.2	8.0
Varyans (Variance)	0.099270	0.316669	0.112754	17.080129
Standart Sapma (Standard Deviation)	0.315071	0.562733	0.335789	4.132811
Outlier Count	2	49	79	0

Seçilen nitelikler için beş sayı özeti, ortalama, mod, çeyrekler arası genişlik (IQR), varyans, standart sapma ve aykırı değer sayıları hesaplanmıştır. Sonuçlara göre Hardener ve Wax niteliklerinde aykırı değer sayısının daha fazla olduğu gözlemlenmiştir.

BOXPLOT ÇİZİMİ :


ESA_amperage Boxplot Yorumu

ESA_amperage niteliğinde verilerin büyük çoğunluğunun 0 değerine yakın toplandığı görülmektedir. Boxplot grafiğinde birkaç yüksek değerli aykırı gözlem bulunmaktadır. Bu durum veri dağılımının dengesiz olduğunu ve bazı gözlemlerin diğerlerinden belirgin şekilde ayrıldığını göstermektedir.




Wax Boxplot Yorumu

Wax niteliğinde verilerin çoğunluğu 2.4 ile 2.7 aralığında toplanmıştır. Grafik üzerinde çok sayıda aykırı değer bulunduğu görülmektedir. Özellikle düşük değerli gözlemler veri dağılımından belirgin şekilde ayrılmaktadır. Bu durum Wax niteliğinde dağılımın homojen olmadığını göstermektedir.



Hardener Boxplot Yorumu

Hardener niteliğinde verilerin büyük kısmı 0.8 ile 1.0 aralığında yoğunlaşmıştır. Boxplot grafiğinde hem düşük hem de yüksek değerlerde çok sayıda aykırı gözlem bulunmaktadır. Bu durum veri dağılımında değişkenliğin yüksek olduğunu göstermektedir.



Roller_durometer Boxplot Yorumu

Roller_durometer niteliğinde verilerin büyük kısmının 30 ile 38 aralığında yoğunlaştığı görülmektedir. Medyan değeri yaklaşık 34 civarındadır. Boxplot üzerinde belirgin bir aykırı değer gözlenmemiştir. Bu durum niteliğin daha dengeli bir dağılıma sahip olduğunu göstermektedir.

2. X veri kümesi için aşağıdaki işlemleri gerçekleştiriniz.

a) Veri kümesinin e-postada belirtilen her bir niteliği için ayrı ayrı [0-1] aralığına **min-max normalizasyon** ve **z-score normalizasyon** değerlerini hesaplayınız.

b) Ayrık olmayan nitelik değerlerini (**continuous attributes**) *n eşit genişlik (n equal-width)* bölme yöntemleri ile ayrık hale dönüştürünüz (n değerini kendiniz belirleyebilirsiniz). Her bir yöntem sonucu elde edilen verilerin her bir niteliği için frekans tabanlı histogram grafiklerini çiziniz. Veri kümenizde belirtilen tüm nitelikler ayrık (discrete) ise bu seçeneği ihmal ediniz. Sadece sürekli değerli nitelikler için gerçekleştirilecektir.

A)

Veri kümesindeki sürekli nitelikler için min-max normalizasyon uygulanmış ve tüm değerler [0-1] aralığına dönüştürülmüştür. :

MIN MAX NORMALIZATION				
	ESA_amperage	Wax	Hardener	Roller_durometer
0	0.0	0.806452	0.333333	0.272727
1	0.0	0.806452	0.233333	0.272727
2	0.0	0.806452	0.433333	0.545455
3	0.0	0.741935	0.200000	0.318182
4	0.0	0.806452	0.266667	0.545455

Sürekli nitelikler için z-score normalizasyon uygulanmış ve her bir veri değeri ortalama ve standart sapmaya göre standartlaştırılmıştır. :


Z SCORE NORMALIZATION				
	ESA_amperage	Wax	Hardener	Roller_durometer
0	-0.056521	0.171131	0.118715	-0.124629
1	-0.056521	0.171131	-0.774704	-0.124629
2	-0.056521	0.171131	1.012133	1.327167
3	-0.056521	-0.184277	-1.072510	0.117337
4	-0.056521	0.171131	-0.476898	1.327167

B)

Sürekli nitelikler eşit genişlik (equal-width) bölme yöntemi kullanılarak 5 aralığa ayrılmış ve ayrık hale dönüştürülmüştür. :


DISCRETIZED DATA				
	ESA_amperage	Wax	Hardener	Roller_durometer
0	0	4	1	1
1	0	4	1	1
2	0	4	2	2
3	0	3	0	1
4	0	4	1	2

HİSTOGAM GRAFİKLERİ:




- **ESA_amperage Histogram Yorumu**

ESA_amperage niteliğinde verilerin büyük kısmının düşük değer aralıklarında toplandığı görülmektedir. Yüksek değerli gözlemler daha az sayıdadır.




- **Wax Histogram Yorumu**

Wax niteliğinde verilerin çoğunluğu orta değer aralıklarında yoğunlaşmıştır. Dağılım belirli aralıklarda kümelenme göstermektedir.



- **Hardener Histogram Yorumu**

Hardener niteliğinde düşük ve orta aralık değerlerinin daha sık gözlemlendiği görülmektedir. Bazı aralıklarda frekans yoğunluğu diğerlerine göre daha yüksektir.



- **Roller_durometer Histogram Yorumu**

Roller_durometer niteliği daha dengeli bir dağılım göstermektedir. Veriler belirli aralıklar boyunca yayılmış durumdadır.

Genel Yorum

Histogram grafiklerine göre niteliklerin veri dağılımları birbirinden farklılık göstermektedir. Bazı niteliklerde belirli aralıklarda yoğunlaşma gözlenirken bazı niteliklerde dağılım daha dengeli gerçekleşmiştir. Equal-width discretization yöntemi sürekli verilerin belirli aralıklara ayrılmasını sağlamıştır.

3. X veri kümesi için e-postada belirtilen her bir niteliğin bilgi kazancı (**information gain**) değeri hesaplanacaktır. Sürekli değerli (Ayrık olmayan, Continuous) olan nitelikler varsa aşağıdaki işlemleri gerçekleştiriniz. Veri kümenizin belirtilen niteliklerinin tamamı ayrık (discrete) ise a ve b seçeneklerini ihmal ediniz ve direkt olarak bilgi kazancı değerlerini hesaplayınız.

a) Veri kümesinde ayrık olmayan nitelik değerlerini 4 eşit genişlik (4 equal-width) değeri olacak şekilde parçalara ayırdıktan sonra her bir nitelik için *bilgi kazancını* (**information gain**) hesaplayınız.

b) Veri kümesinde ayrık olmayan nitelik değerlerini 5 eşit genişlik (5 equal-width) değeri olacak şekilde parçalara ayırdıktan sonra her bir nitelik için *bilgi kazancını* (**information gain**) hesaplayınız.

A)

INFORMATION GAIN - 4 BINS		
	Attribute	Information Gain (4 bins)
0	ESA_amperage	0.019074
1	Wax	0.035534
2	Hardener	0.000000
3	Roller durometer	0.049213

B)

INFORMATION GAIN - 5 BINS		
	Attribute	Information Gain (5 bins)
0	ESA_amperage	0.000000
1	Wax	0.053018
2	Hardener	0.048086
3	Roller durometer	0.023107

YORUM:

4 equal-width ve 5 equal-width discretization işlemleri sonrasında information gain değerleri hesaplanmıştır. Sonuçlara göre bazı niteliklerin sınıf tahmini açısından diğerlerine göre daha fazla bilgi sağladığı gözlemlenmiştir. Information gain değeri yüksek olan niteliklerin, “band” ve “noband” sınıflarını birbirinden ayırmada daha etkili olduğu anlaşılmıştır. Ayrıca kullanılan eşit genişlik (equal-width) sayısının information gain değerlerini etkilediği ve discretization işleminin sonuçlar üzerinde önemli rol oynadığı görülmüştür.

SONUC:

Bu çalışmada bands.dat veri seti üzerinde veri ön işleme ve istatistiksel analiz işlemleri gerçekleştirilmiştir. Seçilen sürekli nitelikler üzerinde normalizasyon, ayırıklaştırma, aykırı değer analizi ve information gain hesaplamaları uygulanmıştır. Elde edilen sonuçlara göre bazı niteliklerin sınıf tahmini açısından daha yüksek bilgi sağladığı gözlemlenmiştir. Ayrıca discretization işlemlerinin information gain sonuçlarını etkilediği görülmüştür.